

SAFE CONGO

Système d'Alerte et de Prévision Épidémiologique

Rapport complet du pipeline Machine Learning

Du chargement des données brutes à l'obtention des résultats

Projet	SAFE CONGO — Surveillance épidémiologique RDC
Données	Dataset 2022 (123 686 lignes) + Dataset 2023 (29 058 lignes)
Maladies	24 maladies surveillées
Méthode	Machine Learning — Régression par maladie + Walk-forward CV
Résultat	R^2 pondéré = 96.9% F1 global (micro) = 88.8%

Ce document explique chaque étape du processus de façon simple et détaillée.

Table des matières

1. Le point de départ : comprendre les données brutes
2. Chargement du dataset 2023
3. Chargement du dataset 2022 et fusion
4. Étape 1 du nettoyage : suppression des colonnes inutiles
5. Étape 2 du nettoyage : traitement des valeurs manquantes
6. Étape 3 du nettoyage : correction des dates
7. Étape 4 du nettoyage : suppression des doublons
8. Étape 5 du nettoyage : normalisation des noms de maladies
9. Agrégation nationale par semaine et par maladie
10. Traitement des valeurs aberrantes (outliers)
11. Gestion des séries creuses
12. Feature Engineering : créer les variables pour le ML
13. Entraînement des modèles ML
14. Walk-forward Cross-Validation
15. Sélection du meilleur modèle par maladie
16. Les résultats obtenus
17. Performance globale du système
18. Difficultés rencontrées et solutions
19. Conclusion

1. Le point de départ : comprendre les données brutes

Avant de faire du Machine Learning, il faut d'abord comprendre d'où viennent les données et ce qu'elles représentent.

Qui collecte ces données ?

En République Démocratique du Congo (RDC), le Ministère de la Santé collecte chaque semaine le nombre de cas de différentes maladies dans chaque zone de santé du pays. Ces données sont enregistrées dans un système informatique et exportées en fichiers Excel.

Que contient un fichier Excel brut ?

Chaque ligne du fichier représente un rapport d'une zone de santé pour une semaine donnée. Voici les colonnes importantes :

Colonne	Signification	Exemple
PROV	Province (région)	Kinshasa
ZS	Zone de Santé	Binza Météo
MALADIE	Nom de la maladie	PALUDISME SUSP
DEBUTSEM	Date du début de la semaine	2023-02-20
TOTALCAS	Nombre total de cas	142
TOTALDECES	Nombre total de décès	2
POP	Population de la zone	85000
NUMSEM	Numéro de la semaine (1-52)	8

Au total, le fichier 2023 contient **29 058 lignes** et le fichier 2022 contient **123 686 lignes**. Ensemble, ils couvrent **28 maladies différentes** et **plus de 500 zones de santé** réparties dans **26 provinces**.

■ Imaginez un carnet de rapport de santé rempli par des infirmiers dans tout le pays, chaque lundi matin. C'est exactement ce que ces fichiers représentent.

2. Chargement du dataset 2023

Pourquoi c'est compliqué ?

Le fichier Excel fourni par le ministère a une particularité : il contient techniquement plus de **16 000 colonnes** (la majorité vides, artefacts de l'outil d'export). Si on essaie de le charger normalement avec pandas, le programme plante avec une erreur de mémoire (MemoryError).

La solution : lecture intelligente avec openpyxl

Au lieu de lire tout le fichier, on utilise openpyxl en mode lecture seule et on limite la lecture aux **30 premières colonnes** uniquement, là où se trouvent toutes les données utiles.

```
wb = openpyxl.load_workbook(path, read_only=True, data_only=True) ws = wb.active #  
Lire uniquement les 30 premières colonnes for row in ws.iter_rows(max_col=30,  
values_only=True): ...
```

On ne conserve que les **20 colonnes utiles** définies à l'avance (PROV, ZS, MALADIE, DEBUTSEM, TOTALCAS, TOTALDECES, etc.).

Résultat du chargement 2023

Paramètre	Valeur
Fichier source	drc-2023_sem08.xlsx
Lignes chargées	29 058
Colonnes utiles conservées	20
Maladies présentes	28
Provinces couvertes	26

■ Seule la semaine 08 de 2023 est disponible dans ce fichier, c'est pourquoi il y a moins de lignes que pour 2022 (qui couvre jusqu'à la semaine 40).

3. Chargement du dataset 2022 et fusion

Pourquoi fusionner deux années ?

Un modèle ML apprend à partir des exemples qu'on lui montre. Plus on lui montre d'exemples, mieux il apprend. Avec seulement les 8 premières semaines de 2023, on aurait trop peu de données pour certaines maladies rares. L'année 2022 apporte **123 686 lignes supplémentaires**, ce qui enrichit considérablement l'apprentissage.

Comment se fait la fusion ?

Les deux fichiers ont exactement la même structure (mêmes colonnes). On les empile simplement l'un après l'autre :

```
df_2023 = charger('drc-2023_sem08.xlsx') # 29 058 lignes
df_2022 = charger('drc-2022_sem40.xlsx') # 123 686 lignes
# Fusion = empilement vertical des deux tableaux
df_total = pd.concat([df_2022, df_2023], ignore_index=True) # Résultat : 152 744 lignes
```

Résultat de la fusion

Source	Lignes	Semaines couvertes
Dataset 2022	123 686	Semaine 01 → Semaine 40 (2022)
Dataset 2023	29 058	Semaine 01 → Semaine 08 (2023)
TOTAL après fusion	152 744	2022 + début 2023

■ Imaginez deux carnets de notes. Vous les collez l'un à la suite de l'autre pour obtenir un seul grand carnet. C'est exactement ce que fait `pd.concat()`.

4. Étape 1 du nettoyage : suppression des colonnes inutiles

Après la fusion, on dispose de 20 colonnes. Certaines ne servent à rien pour notre analyse ou sont redondantes. Les supprimer allège le tableau et évite que le modèle apprenne de fausses corrélations.

Colonnes supprimées :

Colonne supprimée	Pourquoi ?
NUM	Numéro de ligne technique, aucune valeur épidémiologique
RecStatus	Statut d'enregistrement interne au système
UniqueKey	Clé technique, pas de signification médicale
LETAL / ATTAQ	Calculs dérivés de TOTALCAS et TOTALDECES (redondants)
C328TNN / DTNN	Données tétanos néonatal déjà incluses dans les totaux

■ *Garder des colonnes inutiles ne rend pas le modèle plus intelligent. Au contraire, cela peut le perturber — c'est ce qu'on appelle le 'bruit'.*

5. Étape 2 du nettoyage : traitement des valeurs manquantes

Le problème

Dans les données réelles de terrain, des valeurs sont parfois manquantes. Un infirmier peut oublier de remplir une case, ou une zone de santé peut ne pas avoir rapporté ses données pour une semaine donnée.

La solution par type de colonne

Type de donnée	Traitement appliqué	Raison
Colonnes d'âge (C011MOIS, D011MOIS...)	NaN → 0	Manquant = 0 cas dans ce groupe d'âge
Population (POP = 0)	0 → Vide (NaN)	Une population de zéro est une erreur, pas une vraie valeur
Zone de santé manquante	Ligne supprimée	Sans ZS, on ne sait pas d'où vient le rapport
Maladie manquante	Ligne supprimée	Un cas sans maladie identifiée est inutilisable
TOTALCAS manquant	Ligne supprimée	Un rapport sans nombre de cas est vide

■ *Règle simple : si une donnée est vraiment absente et ne peut pas être estimée de façon fiable, il vaut mieux la supprimer que d'inventer une valeur.*

6. Étape 3 du nettoyage : correction des dates

Le problème

Les dates sont cruciales dans notre analyse car on travaille sur des séries temporelles (évolution dans le temps). Des dates incorrectes détruiraient l'ordre chronologique et fausseraient complètement les prédictions.

Types d'erreurs de dates trouvées

Type d'erreur	Exemple	Nombre trouvé	Action
Date illisible / texte	'NON RENSEIGNÉ'	122	Ligne supprimée
Année aberrante	01/01/2102 (erreur de saisie)	553	Ligne supprimée
Année hors plage	< 2020 ou > 2030	Inclus ci-dessus	Ligne supprimée

On accepte uniquement les dates entre **2020 et 2030**. L'anomalie la plus fréquente était des dates en **2102** (probablement une erreur de saisie : 2102 au lieu de 2021/2022).

■ Si une ligne dit qu'un cas de paludisme a eu lieu en 2102, elle ne peut pas servir à prédire quoi que ce soit. On la supprime.

7. Étape 4 du nettoyage : suppression des doublons

Le problème

Parfois, le même rapport est enregistré deux fois dans le système (double saisie, erreur de synchronisation). Si on garde les doublons, le modèle va croire qu'il y a eu deux fois plus de cas.

Comment détecter un doublon ?

Un doublon est une ligne avec exactement la même combinaison de :

- Même date de début de semaine (DEBUTSEM)
- Même maladie (MALADIE)
- Même zone de santé (ZS)
- Même province (PROV)

Résultat	Valeur
Doublons détectés et supprimés	5 072
Lignes avant suppression	152 744
Lignes après suppression	147 672

■ Garder un doublon revient à compter un patient deux fois. On les supprime en ne gardant qu'une seule occurrence de chaque combinaison unique.

8. Étape 5 du nettoyage : normalisation des noms de maladies

Le problème

Dans les fichiers bruts, les noms de maladies sont des codes techniques difficiles à lire et parfois incohérents entre les deux années.

Exemples de codes bruts et leurs traductions :

Code brut (fichier Excel)	Nom normalisé utilisé
PALUDISME SUSP	Paludisme (suspect)

Code brut (fichier Excel)	Nom normalisé utilisé
PALUDISME CONF	Paludisme (confirmé)
DIARRHEE DHY M5	Diarrhée aqueuse
DIARR SANGLANTE	Diarrhée sanglante
FIEVRE TYPHOIDE	Fièvre typhoïde
IRA	Infection respiratoire aiguë

Cette normalisation garantit que "'PALUDISME SUSP" en 2022' et "'PALUDISME SUSP" en 2023' sont bien reconnus comme la même maladie.

Bilan global du nettoyage

Étape	Lignes supprimées	Raison
Dates invalides	122	Dates illisibles ou format incorrect
Dates hors plage (2102...)	553	Erreurs de saisie manifestes
Doublons exacts	5 072	Même rapport saisi deux fois
Lignes critiques vides	18 (estimé)	ZS / MALADIE / TOTALCAS manquants
TOTAL supprimé	5 765	—
RÉSULTAT FINAL	146 979 lignes	Données propres et fiables

9. Agrégation nationale par semaine et par maladie

Pourquoi agréger ?

Après le nettoyage, on a encore 146 979 lignes — une par zone de santé par semaine. Pour construire un modèle de prévision nationale, on n'a pas besoin d'autant de détail. On regroupe toutes les zones de santé ensemble pour obtenir le **total national par semaine et par maladie**.

Comment ?

Pour chaque maladie, pour chaque semaine, on additionne les cas de toutes les zones :

```
aggrege = donnees_nettoyees .groupby(['DEBUTSEM', 'MALADIE']) .agg({'TOTALCAS':  
'sum', 'TOTALDECES': 'sum'}) .reset_index()
```

Résultat

On passe de **146 979 lignes** (une par zone/semaine) à environ **2 558 lignes** (une par maladie/semaine au niveau national). C'est cette version agrégée qui sera utilisée pour l'entraînement ML.

■ *C'est comme si, au lieu de compter les malades dans chaque hôpital séparément, vous les additionniez pour obtenir le total national.*

10. Traitement des valeurs aberrantes (outliers)

C'est quoi un outlier ?

Un outlier est une valeur extrême qui sort complètement de l'ordinaire. Par exemple, si une semaine normale de paludisme montre 10 000 cas, une valeur de 2 000 000 cas pour une seule semaine est probablement une erreur de saisie (zéros en trop).

La méthode IQR (Interquartile Range)

On utilise une méthode statistique robuste appelée IQR :

- $Q1$ = valeur en dessous de laquelle se trouvent 25% des données
- $Q3$ = valeur en dessous de laquelle se trouvent 75% des données
- $IQR = Q3 - Q1$ (l'étendue du milieu)
- Seuil haut = $Q3 + (3 \times IQR)$
- Toute valeur au-dessus du seuil est ramenée à ce seuil (capping)

On utilise un facteur de **3.0** (au lieu de 1.5 habituellement) pour être conservateur et **ne pas supprimer les vrais pics épidémiques**. Un vrai pic de paludisme en saison des pluies ne doit pas être traité comme une erreur.

■ C'est comme dire : 'si une valeur est vraiment anormalement haute et dépasse largement toutes les autres, on la plafonne' — mais sans supprimer les vraies épidémies qui sont naturellement élevées.

11. Gestion des séries creuses

Le problème

Certaines maladies n'ont des rapports que quelques semaines par an (ex: FHA n'a que 40 cas en 27 semaines). Pour ces maladies, plus de 70% des semaines montrent zéro cas — non pas parce qu'il n'y a pas de cas, mais parce que **personne n'a envoyé de rapport** ces semaines-là.

Pourquoi c'est un problème pour le ML ?

Si on dit au modèle que la maladie X a eu 0 cas pendant 50 semaines consécutives puis soudainement 5 cas, le modèle ne peut pas apprendre de tendance. Il sera complètement perdu.

La solution : deux règles

Situation	Action	Résultat
Plus de 70% de semaines à zéro	Maladie supprimée du ML	Pas assez de données pour apprendre
Petit trou de 1-2 semaines à zéro	Interpolation linéaire	On estime la valeur manquante

L'**interpolation linéaire** est simple : si on avait 100 cas la semaine 5 et 120 cas la semaine 8, on estime ~107 cas en semaine 6 et ~113 cas en semaine 7.

■ On passe de 28 maladies après fusion à 24 maladies après ce filtrage. Les 4 maladies supprimées n'avaient pas assez de données pour entraîner un modèle fiable.

12. Feature Engineering : créer les variables pour le ML

Qu'est-ce que le Feature Engineering ?

Un modèle ML ne comprend pas le temps. Il ne sait pas que la semaine 8 suit la semaine 7. On doit lui **traduire le temps en chiffres** qu'il peut analyser. C'est le Feature Engineering.

Variables créées pour chaque maladie

Variable	Description	Utilité
lag_1	Cas de la semaine précédente	La semaine passée est le meilleur prédicteur
lag_2	Cas d'il y a 2 semaines	Tendance à court terme
lag_3, lag_4	Cas des semaines 3 et 4 avant	Tendance sur un mois
ma_2	Moyenne des 2 dernières semaines	Lissage des fluctuations
ma_3, ma_4	Moyenne des 3-4 dernières semaines	Tendance stable
growth_rate	Taux de croissance hebdomadaire	Accélération / décélération
volatility_4w	Écart-type sur 4 semaines	Stabilité ou instabilité
trend	Différence vs moyenne des 4 dernières	Direction de la tendance
month	Mois (1-12)	Saisonnalité mensuelle
quarter	Trimestre (1-4)	Saisonnalité trimestrielle
sin_week / cos_week	Sinus / Cosinus de la semaine épidémi	Cycles annuels
week_rank	Rang chronologique de la semaine	Position dans le temps
cumsum_cases	Cumul total des cas depuis le début	Tendance de fond

Règle anti-triche (No Data Leakage)

IMPORTANT : toutes ces variables sont calculées uniquement avec des données **passées**. On n'utilise jamais la valeur de la semaine actuelle pour la prédire. C'est ce qu'on appelle éviter le 'data leakage' (fuite de données).

■ Exemple : pour prédire les cas de la semaine 10, on utilise les cas des semaines 6, 7, 8, 9 — jamais ceux de la semaine 10 elle-même.

13. Entraînement des modèles ML

L'approche : un modèle par maladie

Plutôt qu'un seul modèle pour toutes les maladies, on entraîne **un modèle spécialisé par maladie**. Le paludisme a des dynamiques très différentes de la fièvre jaune — chaque maladie mérite son propre modèle.

Les 7 algorithmes comparés

Algorithme	Type	Description simple
Linear Regression	Linéaire	Trace une droite entre les points
Ridge Regression	Linéaire régularisée	Droite + pénalisation pour éviter la sur-adaptation
Random Forest	Ensemble	Vote de 200 arbres de décision indépendants
Gradient Boosting	Ensemble	200 arbres construits séquentiellement, chacun corrigeant les erreurs du précédent
KNN (K plus proches voisins)	Instance	Prédire en regardant les semaines les plus similaires
SVR (Support Vector)	Noyau	Trouve la meilleure 'frontière' entre les valeurs
Holt-Winters	Lissage exponentiel	Modèle statistique classique pour les séries temporelles

Transformation logarithmique du target

Les cas épidémiques ont une distribution très asymétrique : beaucoup de semaines avec peu de cas, et quelques semaines avec des milliers de cas. On applique une **transformation log** pour équilibrer :

```
y_log = log(1 + nombre_de_cas) # transformation # Entraînement sur y_log #  
Prédiction finale : exp(prédiction) - 1 (retour à l'échelle réelle)
```

Cela améliore significativement les performances de tous les modèles car ils travaillent sur des valeurs plus uniformément distribuées.

Sélection automatique des meilleures features

Pour chaque maladie, un Random Forest rapide (50 arbres) est d'abord utilisé pour mesurer l'importance de chaque variable. On ne garde que les variables dont l'importance est supérieure à la moyenne — avec un minimum de 5 variables.

■ C'est comme choisir uniquement les ingrédients qui améliorent vraiment le goût d'un plat, au lieu de tout mettre.

14. Walk-forward Cross-Validation (validation croisée temporelle)

Pourquoi une validation spéciale pour les séries temporelles ?

La validation croisée classique (k-fold) mélange les données dans le temps. On pourrait utiliser des données de 2023 pour prédire 2022 — ce qui est impossible en conditions réelles ! On utilise donc la **walk-forward validation**.

Comment ça fonctionne ?

On divise les données en 5 fenêtres temporelles successives :

Fold	Données d'entraînement	Données de test
1	Semaines 1 à 20%	Semaines 20% à 40%
2	Semaines 1 à 40%	Semaines 40% à 60%
3	Semaines 1 à 60%	Semaines 60% à 80%
4	Semaines 1 à 80%	Semaines 80% à 100%
5	Semaines 1 à 90%	Semaines 90% à 100%

À chaque fold, on entraîne sur le passé et on teste sur le futur immédiat. Les métriques (R^2 et MAE) sont moyennées sur les 5 folds pour donner une estimation fiable des performances en conditions réelles.

■ C'est comme s'entraîner sur les données de janvier-mars et tester sur avril, puis s'entraîner sur janvier-juin et tester sur juillet, etc.

Résultat global de la Walk-forward CV

Les scores CV R^2 sont systématiquement légèrement inférieurs aux scores test (environ 0.80 en moyenne vs 0.90 en test). C'est normal et attendu — c'est la validation la plus honnête et conservative.

15. Sélection du meilleur modèle par maladie

Critère de sélection

Pour chaque maladie, les 7 algorithmes sont comparés et celui qui obtient le **R² le plus élevé** sur l'ensemble de test (20% des données les plus récentes) est sélectionné comme meilleur modèle.

Réentraînement final sur 100% des données

Une fois le meilleur algorithme identifié, on le réentraîne sur **toutes les données disponibles** (pas seulement 80%). Le modèle de production profite ainsi de chaque information disponible.

Les métriques (R², MAE, RMSE) calculées sur le 20% de test servent uniquement à valider et choisir — le modèle final utilise 100% des données.

Matrice de confusion (niveaux d'alerte)

Pour évaluer la capacité du modèle à détecter les alertes, on discrétise les prédictions en 3 niveaux :

- Faible : cas inférieurs au 1er tiers de la distribution
- Modéré : cas dans le 2e tiers
- Élevé : cas supérieurs au 2e tiers (= situation d'alerte)

La matrice de confusion compare les niveaux réels vs les niveaux prédits pour mesurer si le modèle détecte correctement les situations d'alerte.

16. Les résultats obtenus

Voici les performances de chaque maladie avec son meilleur modèle :

Maladie	Meilleur Modèle	R² (Best)	MAE (Best)	RMSE (Best)	MAPE (Best)
Infection respiratoire aiguë	Gradient Boosting	0.986	2587.47	4488.38	17.5
Diarrhée sanglante	Gradient Boosting	0.98	29.62	42.93	19.1
Paludisme (confirmé)	Gradient Boosting	0.975	9038.05	16831.38	32.0
Paludisme (suspect)	Gradient Boosting	0.967	15896.08	27730.5	13.1
PFA	Gradient Boosting	0.957	2.66	3.94	13.0
Grippe	Gradient Boosting	0.953	2556.73	4148.6	29.9
Fièvre typhoïde	Gradient Boosting	0.953	2005.33	3621.55	48.2
PNEUMONIE	Random Forest	0.943	889.75	1398.86	36.2
Diarrhée aqueuse	Gradient Boosting	0.939	577.12	1115.01	48.7
Rougeole	Gradient Boosting	0.934	239.95	359.35	30.4
COVID-19	Gradient Boosting	0.906	57.59	83.01	21.3
FIEVRE JAUNE	SVR	0.882	1.38	2.32	13.9
TETANOS MATERNE	Linear Regression	0.865	0.24	0.32	21.2
MAPI LEGERES	Random Forest	0.823	21.6	31.1	38.6
Monkeypox	SVR	0.808	16.18	25.32	30.0
Méningite	Gradient Boosting	0.8	14.19	29.14	26.0
Choléra	Gradient Boosting	0.736	96.74	151.24	28.6
TNN	Gradient Boosting	0.72	2.62	4.42	23.9
FHA	Ridge Regression	0.72	0.14	0.2	9.0
COQUELUCHE	SVR	0.672	4.42	5.11	40.6
DECES MATERNELS	Gradient Boosting	0.439	17.39	28.83	40.7
MAPI GRAVES	Linear Regression	0.007	0.67	0.77	29.0
RAGE	Ridge Regression	-0.559	4.52	9.35	43.7
PESTE	Linear Regression	-5.951	0.75	0.87	36.5

Les R² en vert indiquent les maladies où le modèle explique plus de 90% de la variabilité — ce qui est excellent.

17. Performance globale du système

Comment calculer une performance globale ?

Chaque maladie a son propre R^2 . Pour obtenir un chiffre global représentatif, on utilise la **moyenne pondérée par le volume de cas**.

Formule utilisée

Pour chaque maladie i , on connaît son R^2_i et son nombre total de cas :

Variable	Description
R^2_i	Performance du modèle pour la maladie i
$w_i = \text{Total_cas}_i$	Poids = nombre total de cas de la maladie i
R^2 pondéré	$(\sum R^2_i \times w_i) / (\sum w_i)$

Pourquoi pondérer par les cas ?

La maladie PESTE a un $R^2 = -5.95$ (très mauvais) mais seulement 628 cas. Le Paludisme (suspect) a un $R^2 = 0.967$ (excellent) et 16 millions de cas. Si on donne le même poids aux deux, la PESTE détruirait la moyenne. Ce n'est pas représentatif de la réalité épidémiologique.

Résultats globaux

Métrique	Valeur	Interprétation
Maladies modélisées	24	Toutes les maladies surveillées
Total cas couverts	37 589 329	Plus de 37 millions de cas au total
R^2 moyen simple	47.7%	Tiré vers le bas par les maladies rares
R^2 moyen pondéré (cas)	96.9%	Performance réelle sur la charge épidémique totale
MAPE moyen global	28.8%	Erreur en % sur l'ensemble des maladies
F1 Macro (par maladie)	81.6%	Qualité moyenne de détection d'alerte par maladie
F1 Micro (global)	88.8%	Qualité globale sur toutes les prédictions d'alerte

✓ R^2 pondéré = 96.9% | F1 Micro = 88.8%

■ Pour un système de surveillance épidémiologique en conditions réelles (données imparfaites, zones de santé isolées, sous-déclaration), ces résultats sont considérés comme excellents.

18. Difficultés rencontrées et solutions

Difficulté	Description	Solution
MemoryError au chargement	Fichier Excel avec 16 000+ colonnes videtur	paraleliser le chargement en mode read_only, limitée aux 30 premières colonnes
Anomalie 2102	553 lignes avec des dates en l'an 2102 (erreur de saisie évidente)	Filtrage de saisie évidente, dates entre 2020 et 2030 sont acceptées
Déséquilibre des maladies	Paludisme : 16M cas vs FHA : 40 cas	Transformation log1p + normalisation par maladie + pondération par nombre de cas
Data leakage	Risque d'utiliser des données futures pour prédire le passé	mobiles avec shift(1) obligatoire, TimeSeriesSplit
Séries creuses	Certaines maladies ont 70%+ de semaines sans signal	Suppression (ou signalisation) des séries creuses + interpolation des petits trous
Outliers extrêmes	Valeurs aberrantes qui pourraient être de vraies épidémies	seulement pour ne supprimer que les erreurs évidentes

19. Conclusion

Résumé du pipeline en 9 étapes

#	Étape	Résultat
1	Chargement 2023 (lecture sélective)	29 058 lignes
2	Chargement 2022 + Fusion	152 744 lignes
3	Nettoyage (dates, doublons, NaN)	146 979 lignes propres
4	Agrégation nationale par semaine/maladie	~2 558 lignes
5	Traitement outliers (IQR ×3)	Valeurs aberrantes plafonnées
6	Filtrage séries creuses	24 maladies retenues
7	Feature Engineering (lags, moyennes, saisonnalité)	15+ variables par maladie
8	Comparaison de 7 algorithmes + Walk-forward CV	Meilleur modèle identifié
9	Réentraînement final sur 100% des données	24 modèles de production

Ce que le système peut faire

- Prédire le nombre de cas de 24 maladies pour les prochaines semaines
- Détecter automatiquement les situations d'alerte (niveau Élevé)
- Fournir une aide à la décision pour les autorités sanitaires de RDC
- Fonctionner avec des données réelles et imparfaites de terrain

Performance finale

Indicateur clé	Résultat final
R² pondéré (régression)	96.9% — Excellent
F1-Score global (alertes)	88.8% — Très bon
Maladies couvertes	24 sur 28 (86%)
Données utilisées	37 millions de cas 2022 + 2023

Ce pipeline représente une approche rigoureuse et reproductible pour la surveillance épidémiologique par Machine Learning en RDC.