



UNIVERSITÉ NOUVEAUX HORIZONS

Faculté des Sciences Informatiques

PROJET FINAL MAL1471 — 2026

Phase 2 : Analyse du paysage des données

Dirigé par : Pr. EMMANUEL KALUNGA | Ass. ORTEGA-KABWE

MANKAND-A-MUTEB JOSÉE

Matricule : SI/20223393 — L4 Génie Logiciel

Organisme : INPP – Direction Provinciale Haut-Katanga (Lubumbashi)

Unité : Pool Informatique / Cellule de Développement

Date de remise : 6 juin 2026

Année Académique 2025-2026

Introduction

La Phase 1(a) a décrit l'INPP Haut-Katanga : établissement public de formation professionnelle en transition numérique, où j'effectue mon stage en tant que **stagiaire développeuse** au sein du Pool Informatique / Cellule de Développement. La Phase 1(b) a cartographié le flux principal de traitement d'une demande interne de développement ou d'amélioration d'un module métier, en sept étapes (de la demande du besoin à la mise en service via XAMPP). La présente analyse adopte un autre angle : **les données** générées, consommées ou perdues à chaque étape de ce flux. Chaque source et chaque lacune ci-dessous est explicitement rattachée à une étape du VSM Phase 1(b). Il ne s'agit pas d'une modélisation : c'est un inventaire et une analyse des lacunes, fondation de la Phase 3.

1. Inventaire des données (Data Inventory)

Cinq sources majeures visibles dans la cartographie Phase 1(b). Les trois premières sont les plus structurées ; les deux dernières sont partiellement ou faiblement capturées, ce qui prépare l'analyse des lacunes.

Étape VSM	Source de données	Contenu	Format / Stockage	Propriétaire	Qualité
5 et 7	Base MySQL – module gestion des stagiaires	Fiches stagiaires (identité, entreprise d'origine, formation), présences séance par séance, notes d'évaluation par module, référentiel des entreprises partenaires. Générée lors du développement (étape 5) et enrichie en production (étape 7).	Relationnel – tables MySQL 8 Instance XAMPP sur poste local dédié, réseau interne INPP HK	Cellule de Développement (technique) ; Service Formation (métier)	Bonne pour les champs obligatoires de saisie (identité, dates, statut, notes). Champ motif d'absence souvent vide car les agents cochent seulement présent/absent. Sauvegarde manuelle hebdomadaire, sans entrepôt central.
3	Documents Word / Excel – cahiers des charges métier	Règles de gestion, listes de champs, descriptions d'écrans attendus, comptes rendus de séances d'analyse avec les utilisateurs (Formation, RH).	Fichiers .docx et .xlsx Postes locaux des développeurs – pas de dépôt centralisé	Cellule de Développement + encadreur de stage	Contenu riche mais hétérogène : un document par demande, formats variables, pas de schéma commun. Difficile à agréger automatiquement.
4	Modèles StarUML (.mdj)	Diagrammes de classes, structures de tables prévues, relations entre entités métier avant codage.	Fichiers binaires StarUML (.mdj) Postes locaux de la Cellule Dev	Cellule de Développement	Fiable pour la conception d'un module donné, mais non lié automatiquement aux données de production. Métadonnées projet absentes (version, auteur, date).
2	Cahier de notes – qualification des demandes IT	Demandes reçues, niveau de priorité attribué, affectation à la Cellule Dev, notes de l'échange avec le service demandeur.	Papier + retranscription partielle Cahier physique du Chef du Service Informatique	Chef du Service Informatique	Partiellement capturée : seules les demandes jugées prioritaires sont notées. Pas de format structuré, pas de recherche possible, risque de perte.
6	Retours de test utilisateur (démonstration XAMPP)	Observations des agents métier lors des sessions de test : corrections demandées, bugs signalés, validations fonctionnelles.	Oral + annotations papier ponctuelles Non stocké de façon systématique	Service demandeur + stagiaire (session de test)	Très faible traçabilité : les retours sont donnés à l'oral et implémentés directement sans journal structuré. Décisions non reproductibles.

Source prioritaire observée (étapes 5 et 7)

La base **MySQL du module stagiaires** est la seule source à la fois structurée, en production et directement liée à mon travail quotidien (développement PHP/MySQL sous XAMPP, administration via phpMyAdmin – cf. Phase 1a, section 5). Elle couvre les présences, les évaluations et les fiches d'entreprises partenaires mentionnées dans le questionnaire d'intégration INPP.

2. Analyse des lacunes (Data Gap Analysis)

Trois lacunes identifiées dans le VSM Phase 1(b), aux points de friction que j'avais déjà signalés : capture des demandes (étape 1), centralisation des analyses (étape 3) et journal de tests (étape 6).

2.1 Lacune à l'étape VSM 1

Lacune : Absence de capture formelle des demandes initiales

Les besoins arrivent par WhatsApp, appel téléphonique ou remarque en réunion. Aucun ticket, aucun identifiant de demande, aucun horodatage structuré n'est créé au point de déclenchement du flux (cf. Phase 1b, étape 1 – « données non capturées »).

Ce que le ML permettrait si ces données étaient capturées : **Classification supervisée** de la priorité des demandes IT (haute / normale / basse) et **régression** du délai de traitement, si les champs suivants étaient capturés : service demandeur, type de besoin, urgence déclarée, date de soumission, responsable métier.

2.2 Lacune à l'étape VSM 6

Lacune : Absence de journal structuré des tests et corrections

Lors des démonstrations sur XAMPP, les retours utilisateurs ne sont pas consignés dans un système : pas d'identifiant de bug, pas de gravité, pas de statut de correction. Phase 1b identifiait cette étape comme zone de friction récurrente.

Ce que le ML permettrait si ces données étaient capturées : **Classification** du type de défaut (interface, logique métier, performance) et **régression** du nombre de cycles de correction par module, si chaque retour enregistrerait : module concerné, description, gravité, date, auteur du retour, date de résolution.

2.3 Lacune à l'étape VSM 1 → 2

Lacune : Pas de lien traçable entre demande et livrable

Entre l'étape 1 (demande informelle) et l'étape 2 (qualification), aucun identifiant unique ne suit la demande jusqu'au module déployé. Impossible aujourd'hui de relier une demande WhatsApp au module MySQL résultant.

Ce que le ML permettrait si ces données étaient capturées : **Clustering** non supervisé des profils de demandes similaires (sans étiquette préalable) pour découvrir des familles de besoins récurrents, puis **classification** une fois un historique étiqueté constitué.

3. Tableau des opportunités ML (Data Opportunity Table)

ID	Étape VSM	Type	Source / Lacune	Application ML	Supervisé ?	Étiquette / Features	Faisabilité
S-01	5 / 7	Source	MySQL stagiaires	Classification binaire	Supervisé	Étiquette : statut (abandonné / terminé). Features : présences, notes intermédiaires, secteur entreprise.	Élevée
S-02	5 / 7	Source	MySQL présences	Détection d'anomalies	Non supervisé	Pas d'étiquette requise. Patterns d'absence atypiques par stagiaire ou par session.	Moyenne
S-03	5 / 7	Source	MySQL évaluations	Régression	Supervisé	Étiquette : note finale. Features : notes intermédiaires par module, assiduité.	Moyenne
G-01	1	Lacune	Demandes non capturées (WhatsApp/oral)	Classification	Supervisé (si collecte mise en place)	Étiquette : priorité. Nécessite création d'un formulaire de demande structuré.	Faible (collecte à créer)
G-02	6	Lacune	Retours de test non journalisés	Classification + régression	Supervisé (si collecte mise en place)	Étiquette : type de défaut / nombre de cycles. Nécessite un journal de tests.	Faible (collecte à créer)
G-03	1 → 2	Lacune	Absence de lien demande–livrable	Clustering	Non supervisé	Découverte de familles de demandes sans étiquette. Utile pour prioriser le backlog IT.	Faible

Distinction supervisé / non supervisé : les opportunités S-01 et S-03 requièrent une **étiquette connue** (statut d'abandon, note finale) — ce sont des problèmes supervisés. S-02 et G-03 n'exigent pas d'étiquette préalable : elles relèvent de l'**apprentissage non supervisé** (anomalies, clustering). Les lacunes G-01 et G-02 deviendraient supervisées uniquement après mise en place d'un mécanisme de collecte.

4. Priorisation de l'opportunité ML la plus valorisable

Choix retenu : S-01 – Classification du risque d'abandon des stagiaires (source MySQL, étapes 5 et 7 du VSM).

Justification selon quatre critères :

- **Valeur métier** : l'INPP poursuit la qualité de la formation et la modernisation des outils (Phase 1a, mission observée). Réduire les abandons en cours de stage répond directement à la priorité du service Formation, utilisateur principal de mes modules.
- **Disponibilité des données** : contrairement aux lacunes G-01 et G-02, aucune collecte supplémentaire n'est nécessaire. Les données existent déjà dans MySQL depuis le déploiement des modules (étape 7 – « base opérationnelle » en Phase 1b).
- **Qualité et étiquette** : le champ statut (actif / terminé / abandonné) fournit une étiquette supervisée exploitable. Les features (présences, notes intermédiaires, secteur d'entreprise) sont co-saisies dans le même flux opérationnel.
- **Faisabilité Phase 3** : l'accès technique est réaliste dans le délai du projet (export CSV depuis phpMyAdmin, avec accord de mon encadreur). Les lacunes G-01/G-02 exigeraient de changer les pratiques organisationnelles (ticketing, journal de tests) — hors périmètre du stage.

Les opportunités S-02 (anomalies de présence) et S-03 (régression sur les notes) restent des pistes secondaires sur la même source. Les lacunes G-01 à G-03 sont documentées comme opportunités futures, conditionnées à une évolution du flux VSM.

Réflexion personnelle : En Phase 1(a), j'avais noté ne pas encore maîtriser la gouvernance des données (qui en est propriétaire, qui y accède). Cette Phase 2 m'a permis de répondre partiellement à ces questions : le Service Formation possède les données métier stagiaires, la Cellule Dev en assure la maintenance technique, et le Recouvrement garde ses fichiers Excel hors du flux IT cartographié. Je comprends maintenant pourquoi le brief insiste à relier chaque donnée à une étape du VSM : sans ce lien, on risque de proposer un modèle déconnecté du terrain réel de l'INPP Haut-Katanga.