



UNIVERSITÉ NOUVEAUX HORIZONS

Faculté des Sciences Informatiques

PROJET FINAL MAL1471 — 2026

Phase 2(a) : Exploration et inventaire des données

Dirigé par : Pr. EMMANUEL KALUNGA | Ass. ORTEGA-KABWE

MANKAND-A-MUTEB JOSÉE

Matricule : SI/20223393 — L4 Génie Logiciel

Organisme d'accueil : INPP – Direction Provinciale Haut-Katanga

Date de remise : 6 juin 2026

Année Académique 2025-2026

1. Inventaire des sources de données

Ce tableau recense les principales sources de données identifiées à l'INPP Haut-Katanga, en prolongement direct de la cartographie Phase 1(b) (étapes 5 et 7 = données structurées ; étapes 1, 3 et 6 = données partielles ou perdues).

ID	Source	Type	Propriétaire	Volume estimé	Qualité	Potentiel ML
DS-01	Base MySQL – module stagiaires <i>Tables : stagiaires, presences, evaluations, entreprises</i>	Structuré	Cellule Dev / Service IT	~420 enregistrements stagiaires	Bonne	Élevé
DS-02	Base MySQL – inscriptions & formations <i>Dates incomplètes sur 8 % des fiches</i>	Structuré	Service Formation	~85 sessions / 1 200 inscriptions	Moyenne	Élevé
DS-03	Fichiers Excel – cotisations (Recouvrement) <i>Formats hétérogènes, doublons occasionnels</i>	Semi-structurée	Service Recouvrement	~350 entreprises / an	Variable	Moyen
DS-04	Documents Word – cahiers des charges <i>Texte libre, non indexé</i>	Semi-structurée	Cellule Dev	~15 documents actifs	Faible (non centralisée)	Faible
DS-05	Diagrammes StarUML (.mdj) <i>Métadonnées projet non normalisées</i>	Semi-structurée	Cellule Dev	~12 modèles UML	Bonne (mais dispersée)	Faible
DS-06	Échanges WhatsApp / oral <i>Perte d'information fréquente – cf. Phase 1b étape 1</i>	Non structurée	Services demandeurs	2–4 demandes IT / mois	Très faible	Faible (sans structuration)
DS-07	Registres papier – présences <i>Doublon partiel avec DS-01</i>	Non structurée	Service Formation	Archives 3 ans	Moyenne (saisie manuelle)	Moyen (après numérisation)

2. Documentation écrite de l'exploration des données

2.1 Contexte et lien avec les phases précédentes

La Phase 1(a) m'a permis de décrire l'environnement de stage de l'INPP Haut-Katanga : un établissement public de formation professionnelle en transition numérique, dont le Pool Informatique développe des modules métier en PHP/MySQL sous XAMPP. La Phase 1(b) a cartographié le flux de traitement d'une demande interne de développement et a révélé une **asymétrie nette dans la maturité des données** : certaines sont structurées et stockées dans MySQL (étapes 5 et 7 du VSM), d'autres restent informelles (WhatsApp, notes papier, retours verbaux aux étapes 1 et 6). La Phase 2(a) consiste à passer de cette observation processuelle à un **inventaire concret et vérifiable des données** disponibles, en vue de préparer la définition du problème d'apprentissage automatique en Phase 3.

2.2 Sources structurées : la base MySQL du module stagiaires

La source la plus exploitable est la **base MySQL hébergée sur XAMPP** (DS-01 et DS-02), que j'administre en tant que stagiaire développeuse. Elle centralise les données du module de gestion des stagiaires que j'ai contribué à développer : fiches d'inscription, suivi des présences, résultats d'évaluation et référentiel des entreprises partenaires. Au moment de cette exploration (juin 2026), j'ai recensé environ **420 stagiaires actifs ou archivés, 1 200 inscriptions** liées à 85 sessions de formation, et plusieurs milliers de lignes de présence saisies séance par séance.

J'ai inspecté chaque table via **phpMyAdmin** et exporté un échantillon pour vérification. Les champs critiques (identifiants, dates d'inscription, statut, notes) sont globalement renseignés. Les principales lacunes concernent : le champ motif_absence (78 % de valeurs nulles car les agents cochent seulement « présent / absent »), le secteur des entreprises (20 % manquants) et quelques incohérences entre dates d'inscription et dates de début de formation (environ 8 % des fiches). Malgré ces imperfections, cette base constitue le **socle le plus solide** pour un projet de machine learning, car les données y sont déjà relationnelles, horodatées et liées à un processus métier réel.

2.3 Sources semi-structurées et non structurées

En dehors de MySQL, l'INPP produit un volume important de données **semi-structurées** : les fichiers Excel du service Recouvrement (DS-03) qui suivent les cotisations patronales, les cahiers des charges Word rédigés lors de l'analyse métier (DS-04), et les modèles StarUML de conception (DS-05). Ces sources sont utiles pour comprendre le contexte métier, mais difficilement exploitables en l'état pour l'entraînement de modèles : formats hétérogènes, stockage local non centralisé, absence de schéma commun.

Les sources **non structurées** représentent le principal risque identifié en Phase 1(b). Les demandes IT transitent par WhatsApp ou l'oral (DS-06) ; les registres de présence papier subsistent en parallèle du module numérique (DS-07). J'ai constaté que ces supports génèrent une **double saisie** : l'agent note sur papier puis ressaisit dans le système, introduisant délai et erreurs. Pour l'instant, aucun journal structuré n'existe pour tracer les demandes de développement ni les retours de test — ce qui limite toute analyse prédictive sur le flux IT lui-même.

2.4 Gouvernance, accès et conformité

La question de la gouvernance des données, que j'avais soulevée en Phase 1(a), prend ici une dimension plus concrète. J'ai identifié les rôles suivants :

- **Service Formation** : propriétaire métier des données stagiaires et présences ; accès lecture/écriture au module.
- **Cellule de Développement** : propriétaire technique de la base MySQL ; responsable des sauvegardes locales (export manuel hebdomadaire).
- **Service Recouvrement** : propriétaire exclusif des données de cotisation (DS-03) ; accès non partagé avec l'IT.
- **Direction Provinciale** : destinataire des rapports agrégés, sans accès direct aux bases opérationnelles.

Il n'existe pas encore de politique formelle de protection des données personnelles appliquée aux modules internes. Les fiches stagiaires contiennent des informations sensibles (nom, entreprise, résultats). Pour tout projet ML, une **anonymisation** ou pseudonymisation sera nécessaire, ainsi qu'une validation par mon encadreur et le Chef du Service Formation.

2.5 Évaluation de la qualité des données

J'ai évalué les sources selon cinq critères : complétude, exactitude, cohérence, actualité et accessibilité. La base MySQL (DS-01) obtient une complétude estimée à **88 %** et une exactitude de **92 %** (après détection de 3 % de notes aberrantes, probablement des erreurs de saisie). L'actualité est bonne : les agents Formation mettent à jour les présences chaque semaine. En revanche, l'accessibilité technique reste limitée : pas d'API, pas d'entrepôt central, sauvegarde manuelle. Les données de Recouvrement (DS-03) sont complètes à environ 70 % mais peu accessibles à la Cellule Dev. Les échanges WhatsApp (DS-06) affichent une traçabilité de seulement 15 % — confirmant l'analyse du VSM Phase 1(b).

2.6 Synthèse et préparation de la Phase 3

Cette exploration confirme qu'un projet de machine learning **réaliste et ancré dans le terrain** peut s'appuyer principalement sur la base MySQL du module stagiaires. Les cas d'usage les plus prometteurs que j'ai identifiés sont : la **prédiction du risque d'abandon** (classification), la **détection d'anomalies de présence** et l'**estimation de la performance finale** (régression). Le candidat C-01 (abandon) semble le plus faisable : variable cible disponible (statut), features riches (présences, notes intermédiaires, secteur entreprise) et impact métier direct pour le service Formation. La Phase 3 formalisera le choix du problème, la question de recherche et les critères de succès. Les sources non structurées (DS-06) restent hors périmètre immédiat, sauf si un mécanisme de capture est mis en place durant le stage.

3. Dictionnaire de données – Base MySQL (DS-01)


Extrait du schéma relationnel du module stagiaires. Les champs ont été vérifiés via phpMyAdmin et confrontés aux écrans de saisie utilisés par le service Formation.

Table	Champ	Type	Description	Complétude
stagiaires	id_stagiaire	INT PK	Identifiant unique	Complet
	nom	VARCHAR(80)	Nom de famille	Complet
	prenom	VARCHAR(80)	Prénom	Complet
	sexe	ENUM(M,F)	Genre	2 % manquants
	date_naissance	DATE	Date de naissance	5 % manquants
	id_entreprise	INT FK	Entreprise d'origine	12 % NULL
	id_formation	INT FK	Formation suivie	Complet
	date_inscription	DATE	Date d'inscription	Complet
	statut	ENUM	actif / terminé / abandonné	Complet
presences	id_presence	INT PK	Identifiant séance	Complet
	id_stagiaire	INT FK	Lien stagiaire	Complet
	date_seance	DATE	Date de la séance	Complet
	present	BOOLEAN	Présent (oui/non)	Complet
	motif_absence	VARCHAR(120)	Motif si absent	78 % NULL
evaluations	id_eval	INT PK	Identifiant évaluation	Complet
	id_stagiaire	INT FK	Lien stagiaire	Complet
	module	VARCHAR(100)	Module évalué	Complet
	note	DECIMAL(4,2)	Note sur 20	3 % aberrantes
	date_eval	DATE	Date d'évaluation	Complet
	formateur	VARCHAR(80)	Nom du formateur	15 % manquants
entreprises	id_entreprise	INT PK	Identifiant entreprise	Complet
	raison_sociale	VARCHAR(150)	Nom légal	Complet
	secteur	VARCHAR(60)	Secteur d'activité	20 % manquants
	statut_cotisation	ENUM	à jour / retard / défaut	Variable
formations	id_formation	INT PK	Identifiant formation	Complet
	intitule	VARCHAR(120)	Titre du programme	Complet
	duree_jours	INT	Durée en jours	Complet
	date_debut	DATE	Début de session	8 % manquants
	date_fin	DATE	Fin de session	8 % manquants

4. Matrice de qualité et paysage des données

Critère	Source	Score	Observations
Complétude	DS-01	88 %	Champs clés renseignés ; lacunes sur motif_absence et secteur
Exactitude	DS-01	92 %	3 % de notes aberrantes détectées manuellement
Cohérence	DS-01	85 %	Quelques incohérences dates inscription / formation
Actualité	DS-01	95 %	Mise à jour hebdomadaire par les agents Formation
Accessibilité	DS-01	60 %	Accès local XAMPP ; pas d'API ni export automatisé
Traçabilité	DS-06	15 %	Demandes IT non journalisées – friction Phase 1b
Complétude	DS-03	70 %	Fichiers Excel hétérogènes, colonnes variables
Accessibilité	DS-03	40 %	Accès restreint au service Recouvrement

Schéma du paysage des données – de la production à l'exploitation ML :



5. Candidats problèmes ML (préparation Phase 3)

Ces candidats ne constituent pas encore le problème formalisé (réservé à la Phase 3). Ils résultent de l'exploration et seront priorisés selon la faisabilité et la valeur métier.

ID	Problème candidat	Source(s)	Type ML	Variable cible	Faisabilité
C-01	Prédiction du risque d'abandon <i>Intervention précoce auprès des stagiaires à risque</i>	DS-01 (presences + evaluations + stagiaires)	Classification binaire	statut = abandonné	Élevée
C-02	Détection d'anomalies de présence <i>Alerte automatique aux formateurs</i>	DS-01 (table presences)	Détection d'anomalies	motifs / patterns d'absence inhabituels	Moyenne
C-03	Estimation de la note finale <i>Anticiper les résultats et adapter le suivi pédagogique</i>	DS-01 (evaluations intermédiaires)	Régression	note finale sur 20	Moyenne
C-04	Classification du retard de cotisation <i>Prioriser le recouvrement auprès des entreprises à risque</i>	DS-03 (Excel Recouvrement)	Classification	statut_cotisation	Faible (données dispersées)
C-05	Priorisation des demandes IT <i>Optimiser l'allocation de la Cellule Dev</i>	DS-06 (à structurer)	Classification	priorité haute / normale / basse	Faible (données non capturées)

Recommandation pour la Phase 3

Prioriser le **candidat C-01 – Prédiction du risque d'abandon** : données disponibles dans DS-01, impact direct pour le service Formation, et alignement avec la mission de l'INPP (réduire les abandons en cours de formation professionnelle). Les candidats C-04 et C-05 sont reportés faute de données structurées suffisantes.

Réflexion personnelle : Cette phase m'a fait passer d'une vision « processus » (Phase 1b) à une vision « données » concrète. J'ai appris à interroger une base MySQL comme un futur praticien du machine learning : pas seulement « quelles tables existent », mais « quelle est leur qualité, qui y accède, et que peut-on raisonnablement prédire ? ». Je reste conscient que mes chiffres de complétude sont des estimations basées sur l'observation et des exports ponctuels — ils devront être affinés lors de la Phase 3 avec un jeu de données exporté et nettoyé.